MCDI501

Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 1

Análisis Exploratorio e Inferencial

Informe técnico grupal · 20 %

Título del proyecto: Características de navegación en ventas online

Integrantes: Cristian Hurtado, Jorge Altamirano, Renzo Vilchez y Luis Paredes

Docente: Jean Paul Maidana Gonzáles

Curso: MCDI501 – Estadística Computacional para la Toma de Decisiones

Fecha: 09/10/2026

Repositorio GitHub: https://github.com/RenzoVilchez02/proyectoGrupo2

Índice

Introducción y preguntas del proyecto 3
1. Preparación y carga de datos 4
2. Análisis exploratorio de datos 5
2.1 Comparación descriptiva por compra 6
2.2 Variables categóricas y relaciones 6
2.3 Análisis bivariado mediante Spearman 7
2.4 Valores atípicos y sensibilidad 7
2.5 Filas idénticas 8
3. Estimación de parámetros 9
3.1 Interpretación de los parámetros 9
3.2 Bootstrap y limitaciones 9
4. Pruebas de hipótesis 10
4.1 Supuestos y elección de Welch 10
4.2 Ajuste de Holm e interpretación práctica 11
5. Informe de avance del proyecto 11
6. Notebook y repositorio GitHub 11
7. Bibliografía 12

Introducción y preguntas del proyecto

El objetivo es describir y contrastar las diferencias de navegación entre sesiones con y sin compra, para orientar investigaciones sobre el catálogo y las fichas de productos. En los datos, las sesiones con compra muestran más páginas visitadas y mayor duración media; estas asociaciones no prueban causalidad ni justifican prolongar la visita. La pregunta central es: ¿qué diferencias de navegación observamos entre las sesiones que terminan en compra y las que no?

Se mantienen las seis preguntas específicas del notebook: proporción de compra; distribución de páginas, tiempo y rebote; diferencias de medias de páginas y duración según compra; relaciones entre páginas, duración, rebote y salida; y conversión según visitante, mes y fin de semana. Los resultados se presentan en los apartados 2 a 4 y se sintetizan en el apartado 5.

1. Preparación y carga de datos

Online Shoppers Purchasing Intention, de Sakar y Kastro en UCI **[1]**, reúne 12.330 sesiones y 18 columnas. Revenue indica compra, no importe. La fuente describe usuarios distintos durante un año, pero no documenta muestreo probabilístico y el CSV no permite verificar plenamente independencia. Es el dataset elegido en la fase anterior del proyecto.
Hay diez variables numéricas: conteos y duraciones de páginas administrativas, informativas y de productos; BounceRates, ExitRates, PageValues y SpecialDay. Las ocho categorías son Month, OperatingSystems, Browser, Region, TrafficType, VisitorType, Weekend y Revenue. Los códigos son categorías. ProductRelated_Duration acumula segundos **[2]**, convertidos a minutos para comunicar; no prueba atención activa. Rebote y salida son métricas de páginas, expresadas en porcentaje. PageValues no tiene moneda documentada.

Tabla 1: Calidad del archivo original y decisiones de preparación

Comprobación	Resultado	Decisión
Dimensiones	12.330 filas y 18 columnas	Conservar todas las sesiones
Faltantes y fallos de conversión	0 y 0	Sin imputación
Filas idénticas adicionales	125 (1,01 %)	Conservar; evaluar sensibilidad
Valores fuera del dominio esperado	0	Sin correcciones de rango
Páginas cero con duración positiva	0 en las tres categorías	Sin inconsistencia detectada
Páginas positivas con duración cero	135 administrativas; 226 informativas; 717 de productos	Registrar duda de medición; conservar

Se recuperó el CSV completo de UCI el 09/10/2026 tras detectar decimales alterados en seis columnas. Se verificó SHA-256 y se documentó en data/README.md. Se normalizaron booleanos y se validaron números y rangos. Sin identificadores, filas iguales no prueban duplicación: el análisis principal conserva todas las sesiones, incluidos ceros y extremos; las decisiones alternativas se evalúan por separado.

2. Análisis exploratorio de datos

El notebook caracteriza las diez variables numéricas. La tabla resume las cuatro vinculadas directamente con las preguntas. La media describe el promedio; la mediana, el centro ordenado; la desviación estándar (DE), la dispersión; y el rango intercuartílico (IQR), la amplitud del 50 % central.

Tabla 2: Tendencia central y dispersión en 12.330 sesiones

Variable	Media	Mediana	DE	Q1 / Q3	IQR
Páginas de productos	31,73	18,00	44,48	7,00 / 38,00	31,00
Duración en productos (min)	19,91	9,98	31,89	3,07 / 24,40	21,33
Rebote (%)	2,22	0,31	4,85	0,00 / 1,68	1,68
Salida (%)	4,31	2,52	4,86	1,43 / 5,00	3,57

La media de páginas (31,73) supera la mediana (18), y la duración media (19,91 min) casi duplica su mediana (9,98 min). La cola derecha eleva los promedios. La DE de duración es 31,89 min y el 50 % central está entre 3,07 y 24,40 min. Una sesión central no debe describirse solo por la media.

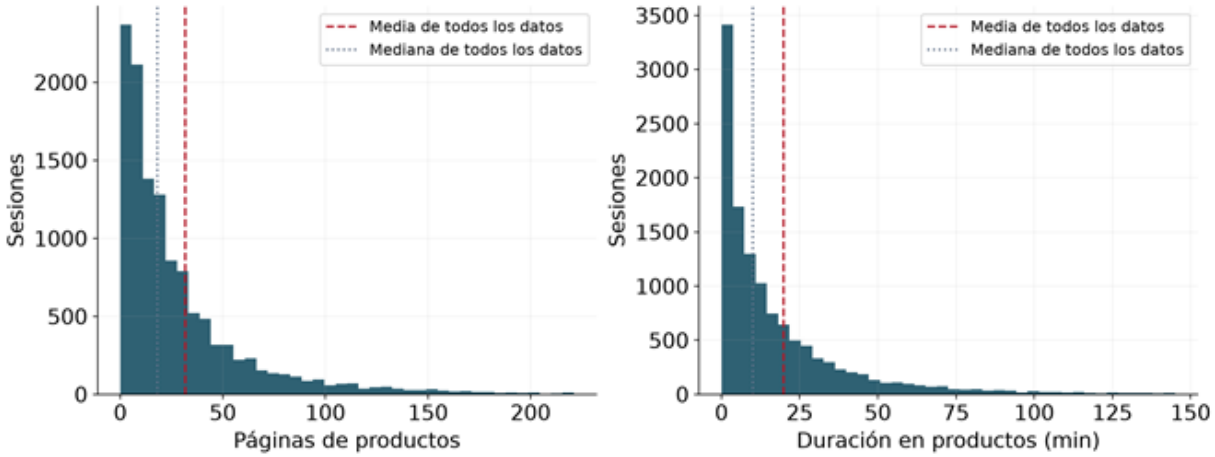


Figura 1 Páginas y duración hasta el percentil 99. Quedan fuera de esta vista 122 y 124 sesiones; se conservan en los cálculos. Líneas: media y mediana del conjunto completo. Fuente: datos UCI; elaboración del grupo a partir del notebook.

Rebote y salida también presentan medias mayores que sus medianas. Los gráficos completos y boxplots están en el notebook. El acercamiento mejora la lectura sin eliminar extremos del análisis.

2.1 Comparación descriptiva por compra

Las sesiones con compra tienen medianas de 29 páginas y 18,50 min, frente a 16 páginas y 8,50 min sin compra. El rebote medio es 0,512 % con compra y 2,532 % sin compra; la salida media es 1,956 % y 4,738 %. Son asociaciones descriptivas. Los dos contrastes formales evalúan medias de páginas y duración, no medianas ni rebote.

2.2 Variables categóricas y relaciones

Revenue registra 1.908 sesiones con compra (15,47 %) y 10.422 sin compra (84,53 %). Diferenciamos frecuencia de una categoría y conversión dentro de ella: un grupo más numeroso puede concentrar compras sin tener mayor conversión.

Tabla 3: Frecuencias y conversión por visitante y momento de la semana

Categoría	Sesiones	% del total	Compras	% compra dentro del grupo
Visitante nuevo	1.694	13,74	422	24,91
Otro visitante	85	0,69	16	18,82
Visitante recurrente	10.551	85,57	1.470	13,93
Entre semana	9.462	76,74	1.409	14,89
Fin de semana	2.868	23,26	499	17,40

Los recurrentes representan el 85,57 % de las sesiones, pero su conversión es 13,93 %, frente a 24,91 % en nuevos. Other reúne solo 85 sesiones. La conversión de fin de semana es 17,40 %, frente a 14,89 % entre semana. Estas comparaciones exploratorias no ajustan por tráfico, campaña o composición de visitantes.

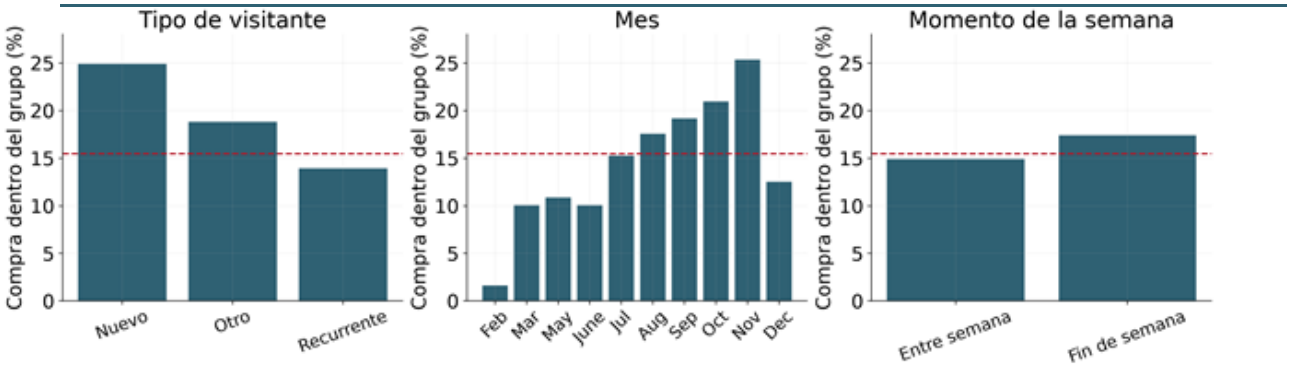


Figura 2 Proporción de compra dentro de cada categoría. Línea discontinua: 15,47 % global. Fuente: datos UCI; elaboración del grupo a partir del notebook.

Noviembre tiene la mayor conversión (25,35 %; 760/2.998) y febrero la menor (1,63 %; 3/184). Faltan enero y abril y los tamaños son distintos: no se interpreta una serie anual completa ni un efecto causal. El notebook incluye frecuencias absolutas, relativas y gráficos para las ocho variables categóricas.

2.3 Análisis bivariado mediante Spearman

Spearman describe asociaciones monótonas por rangos ante asimetría y extremos **[3]**. Páginas y tiempo tienen asociación positiva fuerte (ρ = 0,883); rebote y salida, positiva (ρ = 0,602); páginas y salida, negativa (ρ = -0,519). El mapa y la dispersión del notebook apoyan esta lectura. Las relaciones no demuestran causalidad; páginas y duración comparten información de exploración.

2.4 Valores atípicos y sensibilidad

La regla de 1,5 IQR marca valores fuera de [Q1 - 1,5 × IQR; Q3 + 1,5 × IQR], con IQR = Q3 - Q1 **[7]**. Marca 987 sesiones en páginas (8,00 %), 961 en duración (7,79 %) y 1.551 en rebote (12,58 %). Los límites superiores son 84,5 páginas, 56,40 min y 4,203 %. En variables con IQR cero puede marcar cualquier positivo; no basta para eliminarlo.

La duración máxima es 17,77 horas, en una sesión sin compra con 449 páginas. Merece investigación, pero no confirma error ni actividad continua. Conservamos todas las sesiones del análisis principal; excluir como error requiere evidencia del registro.

Tabla 4: Diferencias entre grupos en escenarios restringidos por variable

Variable	Escenario	n	Excluidas	Diferencia con menos sin
Páginas	Todas	12.330	0	19,496
Páginas	1,5 IQR	11.343	987	8,494
Duración (min)	Todas	12.330	0	13,437
Duración (min)	1,5 IQR	11.369	961	6,198
Rebote (puntos porcentuales)	Todas	12.330	0	-2,020
Rebote (puntos porcentuales)	1,5 IQR	10.779	1.551	-0,278

La diferencia de páginas cae de 19,496 a 8,494 y la de duración de 13,437 a 6,198 min. La dirección se conserva, pero ambas magnitudes se reducen más de la mitad. Rebote pasa de -2,020 a -0,278 puntos porcentuales. El escenario de 3 IQR conserva dirección con magnitudes intermedias; el notebook presenta sus IC.

Los límites globales se aplican por igual a ambos grupos, y cada variable se restringe por separado. Cambia el estimando a medias de sesiones restringidas: no son resultados corregidos del mismo parámetro. Los IC diagnósticos no incorporan incertidumbre de seleccionar límites. No se agregan pruebas buscando significancia.

2.5 Filas idénticas

Sin las 125 filas idénticas adicionales quedan 12.205 sesiones. Las dos decisiones Welch-Holm se mantienen; las diferencias son 19,16 páginas y 13,22 min. Las medias globales cambian +0,99 % en páginas y +1,02 % en duración. Rebote pasa de 2,219 % a 2,037 %: -8,21 % relativo o -0,182 puntos porcentuales. No todo el análisis es insensible. Sin identificadores, conservamos las filas y comunicamos esta alternativa.

3. Estimación de parámetros

Seleccionamos páginas, duración en productos y rebote para describir amplitud, tiempo y abandono. La media muestral estima cada media del proceso de registro. La referencia propuesta son sesiones comparables del mismo sitio y contexto; sin diseño probabilístico, no se garantiza representatividad de otros períodos o tiendas.

El IC principal del 95 % usa distribución t: media ± t crítico × s/√n, con n - 1 grados de libertad **[4]**. La desviación poblacional es desconocida. Los datos individuales no son normales; la aproximación de la media se apoya en n = 12.330, condicionada a independencia razonable y varianza finita. El tamaño no corrige sesgos de selección ni errores de medición.

Tabla 5: Tres medias e intervalos individuales del 95 %

Parámetro estimado	Media	IC t del 95 %	IC bootstrap del 95 %
Páginas de productos	31,731	[30,946; 32,517]	[30,917; 32,544]
Duración en productos (min)	19,912	[19,349; 20,475]	[19,360; 20,499]
Rebote medio (%)	2,219	[2,134; 2,305]	[2,137; 2,308]

3.1 Interpretación de los parámetros

Páginas. La media estimada es 31,731 y el IC t [30,946; 32,517] páginas. Cuantifica incertidumbre sobre el promedio; no es un rango para una sesión típica. La mediana de 18 y la cola deben acompañar su interpretación.

Duración. La media es 19,912 min y el IC [19,349; 20,475] min. Estima tiempo acumulado registrado, no atención activa ni permanencia recomendada. La mediana es 9,982 min.

Rebote. La media de la métrica por sesión es 2,219 %, con IC [2,134; 2,305] %. No es la proporción de sesiones sin compra (84,53 %) ni una tasa global reconstruida con eventos individuales.

3.2 Bootstrap y limitaciones

Como comprobación, usamos IC bootstrap percentiles de 2.000 remuestras con reemplazo, semilla 20261009. Los límites son próximos a los de t; la amplitud cambia +3,64 % en páginas, +1,16 % en duración y -0,04 % en rebote. Es estabilidad frente a esta elección de método, no validación de representatividad o medición.

El 95 % corresponde a la cobertura del procedimiento al repetir muestras comparables bajo los supuestos. No significa que el intervalo contenga al 95 % de las sesiones ni una probabilidad del 95 % sobre un parámetro fijo. Los IC son individuales, no simultáneos, y no cubren sesgo de selección o medición.

4. Pruebas de hipótesis

Para páginas de productos, H_0: μ con compra = μ sin compra; H_1: las medias son distintas. Para duración, H_0 plantea igualdad de medias de tiempo y H_1 que difieren. Ambos contrastes son bilaterales, con n = 1.908 con compra y n = 10.422 sin compra. Se fija α = 0,05 como umbral convencional del avance académico, no como certeza o criterio de utilidad empresarial.

4.1 Supuestos y elección de Welch

Welch compara medias sin exigir igualdad de varianzas **[5]**. Las DE con y sin compra son 58,27 y 40,74 páginas, y 38,54 y 30,06 min. Histogramas, boxplots y Q-Q muestran asimetría y colas; no se afirma normalidad de los datos. La aproximación de las medias depende de tamaños grandes, independencia y varianza finita. La fuente describe usuarios diferentes, pero sin identificadores no podemos verificarlo por completo. No son observaciones pareadas; campañas compartidas pueden afectar independencia.

Tabla 6: Diferencias de medias y resultados de Welch

Variable	Media con compra	Media sin compra	Diferencia	IC 95 % de la diferencia
Páginas de productos	48,21	28,71	19,50	[16,77; 22,23]
Duración (min)	31,27	17,83	13,44	[11,61; 15,26]

Tabla 6b: Estadísticos y decisión con Holm

Prueba	t Welch	Grados de libertad	p sin ajuste	p Holm	Decisión
Páginas	14,002	2.260,4	8.835e-43	8.835e-43	Rechazar H_0
Duración	14,447	2.350,3	2.174e-45	4.348e-45	Rechazar H_0

La diferencia es con compra menos sin compra. Los IC son individuales, no ajustados por Holm. e-43 significa × 10 elevado a -43: los valores p son muy pequeños, no cero.

4.2 Ajuste de Holm e interpretación práctica

Las dos preguntas forman una familia relacionada. Holm controla el error tipo I familiar: ordena los valores p, compara el menor con 0,025 y, si se rechaza, el siguiente con 0,05. Equivalentemente, compara p ajustados con 0,05 **[6]**. Se rechaza H_0 en ambas pruebas. El valor p no es la probabilidad de que H_0 sea verdadera.

Las sesiones con compra registran 19,50 páginas y 13,44 min más, en promedio. Hay evidencia de diferencias bajo los supuestos, pero no de que prolongar la visita cause compras. No se conoce un umbral de relevancia comercial. Las magnitudes deben interpretarse junto con la sensibilidad del apartado 2.3.

5. Informe de avance del proyecto

Las preguntas se responden con mayor exploración de productos en sesiones con compra: 19,50 páginas y 13,44 min más, en promedio. Compra el 15,47 % de las sesiones; páginas y tiempo muestran asociación positiva fuerte. Visitante, mes y fin de semana presentan heterogeneidad descriptiva. Las métricas de rebote y salida son menores con compra.

Las diferencias mantienen dirección al restringir extremos, pero se atenúan fuertemente. La significación no garantiza utilidad comercial. Limitan la inferencia la selección no probabilística, posibles factores de confusión, medición de tiempos, meses ausentes, categorías pequeñas y falta de identificadores. Los IC no cubren estos sesgos.

Proponemos investigar catálogo y fichas: distinguir interés de dificultad, revisar extremos con el registro y estudiar composición por visitante y campaña. Antes de intervenir debe definirse una magnitud útil y un diseño que evalúe efectos. En fases posteriores, verificar disponibilidad temporal de variables como PageValues para evitar filtración de información en modelos.

6. Notebook y repositorio GitHub

F1/Definicion.ipynb se ejecutó desde un kernel nuevo el 09/10/2026: 20 celdas en orden, sin errores y 12 figuras. Usa CSV en data/raw, rutas del repositorio, semilla 20261009 y requirements.txt; se verificó Python 3.13.5. Las cifras corresponden a esa ejecución. Quedan revisión del grupo, reproducción en otro equipo y acceso del docente al GitHub de portada.

7. Bibliografía

[1] Sakar, C. y Kastro, Y. (2018). Online Shoppers Purchasing Intention Dataset. UCI Machine Learning Repository. DOI: https://doi.org/10.24432/C5F88Q. Licencia CC BY 4.0.

[2] Topal, İ. (2019). Estimation of Online Purchasing Intention Using Decision Tree. https://dergipark.org.tr/tr/download/article-file/896156

[3] SciPy. Documentación de spearmanr. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.spearmanr.html

[4] Maidana, J. P. (2026). Intervalos de confianza: cuantificando la incertidumbre estadística. Apunte de MCDI501, Universidad Andrés Bello.

[5] SciPy. Documentación de ttest_ind y prueba de Welch. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_ind.html

[6] R Core Team. Ajuste de valores p mediante Holm. https://stat.ethz.ch/R-manual/R-devel/library/stats/html/p.adjust.html

[7] NIST/SEMATECH. e-Handbook of Statistical Methods. Box Plot. https://www.itl.nist.gov/div898/handbook/prc/section1/prc16.htm

[8] Universidad Andrés Bello (2026). Instrucciones y rúbrica de Sumativa 1, fase 2, MCDI501. Canvas.